NEXA DIGITAL SCHOOL

MÉMOIRE PROFESSIONNEL

Mastère 1 — Data & Intelligence Artificielle

Chef de projet Data et IA — RNCP 37137

Analyse de Sentiment Clients par le Traitement du Langage Naturel (NLP) : Application aux Avis Consommateurs Renault Group

Rédacteur :	Cheikh CISSE
Formation :	Mastère 1 Data & Intelligence Artificielle
Entreprise :	Renault Group
Année :	2025 — 2026
Date de début :	Septembre 2025
Date de rendu :	17 Août 2026

Technologies : Python · TensorFlow · Scikit-learn · NLTK · Transformers (BERT) · Power BI · SQL · MongoDB

SOMMAIRE

1. Présentation du Projet

1.1 Contexte et enjeux de la transformation numérique automobile

1.2 L'intelligence artificielle comme levier stratégique

1.3 Objectifs du projet

2. Descriptif de l'Entreprise — Renault Group

2.1 Histoire et storytelling

2.2 Valeurs, missions et activité principale

2.3 Environnement économique et sociétal

2.4 Environnement technologique et data

3. Étude de Marché et Analyse Concurrentielle

3.1 Analyse du marché automobile mondial

3.2 Analyse concurrentielle — Tesla

3.3 Analyse concurrentielle — Volkswagen Group

4. Problématique et Définition du Besoin

4.1 Identification du problème métier

4.2 Solution proposée et bénéfices attendus

5. Pilotage du Projet et Planification

5.1 Méthode de gestion retenue

5.2 Retroplanning et jalons

5.3 KPI et tableau de bord de suivi

5.4 Estimation budgétaire

6. Exploitation des Données

6.1 Sources et volumétrie des données

6.2 Dictionnaire de données et typographie

6.3 Qualité des données et RGPD

7. Machine Learning et Deep Learning — NLP

7.1 Introduction théorique au NLP et à l'analyse de sentiment

7.2 Algorithmes retenus et justification

7.3 Évaluation des performances

7.4 Visualisation et dashboard

8. Conclusion

Bibliographie

Annexes

1. PRÉSENTATION DU PROJET

1.1 Contexte et enjeux de la transformation numérique dans l'industrie automobile

L'industrie automobile traverse depuis plusieurs années une mutation profonde et sans précédent, façonnée par la convergence de trois grandes révolutions : l'électrification des motorisations, la connectivité des véhicules et la digitalisation des processus industriels et commerciaux. Cette triple transformation redéfinit les règles du marché, les attentes des consommateurs et les impératifs stratégiques des constructeurs. Dans ce contexte, la capacité à exploiter efficacement la donnée constitue un avantage concurrentiel décisif.

Selon l'Agence Internationale de l'Énergie (AIE), les ventes mondiales de véhicules électriques ont atteint 14 millions d'unités en 2023, représentant 18 % du marché global des véhicules neufs, contre seulement 4 % en 2020. Cette croissance exponentielle s'accompagne d'une intensification de la concurrence et d'une pression accrue sur l'expérience client. Les consommateurs, de plus en plus connectés et informés, expriment leurs opinions sur des plateformes numériques variées — forums automobiles, réseaux sociaux, sites d'avis — générant un volume colossal de données textuelles non structurées. Pour un constructeur comme Renault, exploiter cette matière première informationnelle représente à la fois un défi technologique et une opportunité stratégique majeure.

L'Union Européenne, à travers le règlement sur les émissions de CO2, impose aux constructeurs une réduction moyenne de leurs émissions de flotte à 95 g/km dès 2021 et à 0 g/km d'ici 2035 pour les véhicules neufs. Ces contraintes réglementaires accélèrent la transition vers l'électrique, mais elles intensifient également la nécessité pour les marques de fidéliser leurs clients existants et d'en conquérir de nouveaux grâce à une expérience utilisateur différenciante. Dans ce cadre, comprendre et anticiper les sentiments des clients n'est plus une option : c'est une nécessité opérationnelle.

1.2 L'intelligence artificielle comme levier stratégique dans l'automobile

Le recours à l'intelligence artificielle dans le secteur automobile ne se limite plus aux systèmes d'aide à la conduite (ADAS) ou à l'optimisation des chaînes de production. Il s'étend désormais à l'ensemble de la chaîne de valeur : gestion de la relation client, personnalisation de l'offre, détection précoce des défauts qualité, analyse prédictive des comportements d'achat, et monitoring de la réputation de marque. D'après une étude McKinsey & Company publiée en 2023, l'IA pourrait générer jusqu'à 300 milliards de dollars de valeur additionnelle annuelle dans l'industrie automobile mondiale d'ici 2030.

Le traitement automatique du langage naturel (NLP — Natural Language Processing) constitue l'une des branches les plus prometteuses de l'IA appliquée au marketing et à la relation client. Les modèles de type Transformer, dont BERT (Bidirectional Encoder Representations from Transformers) développé par Google en 2018, ont révolutionné la compréhension sémantique des textes et ouvrent des perspectives inédites pour l'analyse automatisée des avis

consommateurs à grande échelle. Ces technologies permettent non seulement de classer les opinions comme positives, négatives ou neutres, mais aussi d'en extraire des thématiques fines, des émotions spécifiques et des signaux d'alerte précoces sur la qualité des produits ou services.

1.3 Objectifs du projet

Le présent projet s'inscrit dans cette dynamique de valorisation de la donnée client au service de la compétitivité de Renault Group. Il vise à concevoir, développer et déployer un système d'analyse automatique des sentiments exprimés par les consommateurs dans leurs avis en ligne portant sur les véhicules et services Renault. Les objectifs opérationnels sont les suivants :

- Collecter et consolider un corpus de données textuelles issues de sources publiques (Kaggle, forums automobiles, plateformes d'avis) portant sur Renault et ses véhicules ;
- Prétraiter et nettoyer les données textuelles afin de les rendre exploitables par des algorithmes de Machine Learning et de Deep Learning ;
- Entraîner et comparer plusieurs modèles de classification de sentiments (régression logistique, SVM, LSTM, BERT fine-tuné) pour identifier la solution la plus performante ;
- Interpréter les résultats obtenus pour en extraire des insights métier actionnables relatifs à la satisfaction client, aux points de friction et aux axes d'amélioration ;
- Restituer les analyses dans un tableau de bord interactif Power BI accessible aux équipes marketing, qualité et direction.

Ce projet s'inscrit pleinement dans la stratégie "futuREady" de Renault Group, qui positionne la data et l'intelligence artificielle comme des piliers fondamentaux de sa transformation et de sa compétitivité à horizon 2025-2030.

2. DESCRIPTIF DE L'ENTREPRISE — RENAULT GROUP

2.1 Histoire et storytelling

Fondée en 1899 par les frères Louis, Marcel et Fernand Renault à Boulogne-Billancourt, la société Renault est l'une des plus anciennes et des plus emblématiques entreprises de l'industrie automobile mondiale. Dès ses premières années, Louis Renault impose sa marque par l'innovation technique : la prise directe, la carrosserie intégrée, les moteurs à refroidissement par eau. La marque au losange remporte ses premiers succès en compétition automobile, asseoyant une réputation d'excellence mécanique qui demeure constitutive de son identité.

Nationalisée en 1945, la Régie Nationale des Usines Renault devient un acteur public central de la reconstruction industrielle française et un laboratoire social pionnier (semaine de quatre semaines de congés payés dès 1955, participation aux bénéfices). La Renault 4, lancée en 1961, puis la Renault 5 en 1972, incarnent une vision démocratique et populaire de l'automobile qui marque durablement plusieurs générations de Français. La privatisation en 1996 ouvre un nouveau chapitre stratégique, marqué par l'alliance fondatrice avec Nissan en 1999 sous l'impulsion de Carlos Ghosn, créant l'un des groupes automobiles les plus importants au monde.

Aujourd'hui, Renault Group rassemble les marques Renault, Dacia, Alpine et Mobilize, et commercialise ses véhicules dans plus de 130 pays. En 2023, le groupe a vendu 2,23 millions de véhicules dans le monde, se positionnant parmi les dix premiers constructeurs automobiles mondiaux. La nomination de Luca de Meo à la tête du groupe en 2020 a inauguré une transformation stratégique ambitieuse, formalisée dans le plan « Renaulution » puis évoluant vers la stratégie « futuREady », visant l'électrification totale de la gamme Renault en Europe d'ici 2030 et une rentabilité durable.

2.2 Valeurs, missions et activité principale

Renault Group articule sa raison d'être autour d'une vision : « Créer un lien durable entre l'automobile, les individus et la société, pour améliorer la vie de tous. » Cette ambition se décline en quatre valeurs fondamentales : l'innovation permanente, la responsabilité sociale et environnementale, l'ouverture et la confiance, et la performance durable. L'activité principale du groupe repose sur la conception, la fabrication et la commercialisation de véhicules particuliers, véhicules utilitaires légers et véhicules électriques, complétée par des services de mobilité, de financement et d'entretien via les entités RCI Financial Services (devenu Mobilize Financial Services) et Renault Retail Group.

Le plan stratégique « futuREady », dévoilé en 2023, structure la transformation du groupe autour de cinq piliers : l'accélération de l'électrification (avec l'objectif de 100 % de la gamme Renault en électrique en Europe d'ici 2030), la maîtrise technologique (avec la création d'Ampere, entité dédiée aux véhicules électriques et aux logiciels), la réduction des coûts, l'expansion des activités de services et le renforcement de la compétitivité de Dacia et Alpine sur leurs segments respectifs.

2.3 Environnement économique et sociétal

En 2023, Renault Group a réalisé un chiffre d'affaires de 52,4 milliards d'euros, en hausse de 13 % par rapport à 2022, avec une marge opérationnelle record de 7,9 %. Ces résultats témoignent du redressement spectaculaire opéré sous la direction de Luca de Meo après les années difficiles de la pandémie et de la pénurie de semi-conducteurs. Sur le plan sociétal, Renault Group emploie environ 105 000 collaborateurs dans le monde et constitue un acteur socio-économique majeur des territoires où il est implanté, notamment en France (sites de Flins, Douai, Maubeuge, Cléon).

Le groupe est confronté à des défis structurels importants : la hausse des coûts des matières premières, la pression concurrentielle des constructeurs chinois sur le segment des véhicules électriques, les incertitudes géopolitiques affectant les chaînes d'approvisionnement, et la nécessité d'adapter ses effectifs et compétences aux nouvelles exigences technologiques. Sur le plan sociétal, l'entreprise s'engage à travers son plan ESG sur la réduction de son empreinte carbone (objectif de neutralité carbone en Europe d'ici 2040) et l'amélioration de la diversité et de l'inclusion au sein de ses équipes.

2.4 Environnement technologique et data

La transformation technologique de Renault Group s'opère à plusieurs niveaux. Au niveau véhicule, le groupe développe des systèmes d'aide à la conduite avancés, des plateformes logicielles embarquées et des architectures électriques/électroniques centralisées permettant les mises à jour à distance (OTA — Over The Air). La Renault Mégane E-Tech Electric, lancée en 2022, et le Renault 5 E-Tech Electric, commercialisé en 2024, incarnent cette nouvelle génération de véhicules nativement connectés et logiciels.

Au niveau du groupe, la création d'Ampere en 2023 — filiale cotée en bourse et dédiée aux véhicules électriques et aux logiciels — marque une étape structurante. Renault a également développé des partenariats stratégiques avec des acteurs technologiques de premier plan : Google (pour les systèmes d'information embarqués Android Automotive), Qualcomm (pour les puces de calcul), et Nvidia (pour les systèmes d'IA embarquée). En matière de données, le groupe collecte et traite des volumes considérables d'informations : données télémétriques des véhicules connectés, données de production issues des usines 4.0, données clients CRM, et données d'avis consommateurs issues des canaux digitaux. Un Data Office central coordonne la gouvernance des données et le déploiement des projets d'intelligence artificielle au sein du groupe.

3. ÉTUDE DE MARCHÉ ET ANALYSE CONCURRENTIELLE

3.1 Analyse du marché automobile mondial et européen

Le marché automobile mondial a retrouvé en 2023 sa dynamique d'avant-crise, avec 88,3 millions de véhicules vendus selon l'OICA (Organisation Internationale des Constructeurs d'Automobiles), en progression de 9 % par rapport à 2022. En Europe, l'Association des Constructeurs Européens d'Automobiles (ACEA) fait état de 10,5 millions d'immatriculations de voitures particulières neuves en 2023, soit une hausse de 13,9 % par rapport à l'année précédente, portée par la reconstitution des carnets de commandes et l'atténuation des pénuries de composants électroniques.

La transition énergétique transforme en profondeur la structure du marché. En 2023, les véhicules électriques à batterie (BEV) représentaient 14,6 % des nouvelles immatriculations en Europe, et les véhicules hybrides rechargeables (PHEV) 8 %, portant la part des véhicules électrifiés à près d'un quart du marché européen (source : ACEA, 2024). La France, marché domestique de Renault, affichait un taux de pénétration des BEV de 16,8 % en 2023 selon les données de l'AVERE France.

Cette transition génère de nouveaux enjeux en matière d'expérience client. Les acheteurs de véhicules électriques sont statistiquement plus connectés, plus exigeants sur la qualité des services numériques et plus prompts à partager leurs expériences en ligne. Une étude JD Power 2023 révèle que 72 % des acheteurs de véhicules neufs consultent des avis en ligne avant leur décision d'achat, et que les problèmes liés aux logiciels embarqués et aux infrastructures de recharge constituent les principales sources d'insatisfaction dans ce segment. Dans ce contexte, la capacité à monitorer et analyser l'opinion des consommateurs en temps quasi réel représente un enjeu compétitif de premier ordre.

Le marché de l'analyse de sentiment et plus largement du NLP appliqué à l'industrie connaît une croissance soutenue. Selon MarketsandMarkets, le marché mondial du NLP était évalué à 20,8 milliards de dollars en 2023 et devrait atteindre 68,1 milliards en 2028, avec un taux de croissance annuel composé (CAGR) de 26,6 %. L'industrie automobile figure parmi les secteurs adoptant le plus rapidement ces technologies pour améliorer leur compétitivité.

3.2 Analyse concurrentielle — Tesla

Tesla, fondée en 2003 par Elon Musk et ses associés, est devenue en moins de deux décennies la référence mondiale du véhicule électrique premium et le symbole de la disruption automobile par la technologie logicielle. En 2023, Tesla a livré 1,81 million de véhicules dans le monde, consolidant sa position de premier constructeur mondial de BEV. Son chiffre d'affaires a atteint 97,7 milliards de dollars, avec une marge opérationnelle de 9,2 % — en recul par rapport à 2022 du fait des baisses de prix agressives pratiquées pour soutenir les volumes.

La force principale de Tesla réside dans son architecture technologique verticalement intégrée : matériel, logiciel embarqué, réseau de recharge Supercharger et service après-vente sont

maîtrisés en propre. Son système de pilotage assisté Autopilot/FSD (Full Self-Driving) génère des volumes considérables de données comportementales qui alimentent en retour l'amélioration continue des algorithmes. Tesla exploite également de façon très poussée l'analyse des avis et comportements clients via son application mobile et ses plateformes communautaires, lui permettant de déployer des correctifs logiciels OTA (Over The Air) en réponse aux remontées terrain en quelques jours.

En revanche, Tesla présente des faiblesses structurelles significatives : des problèmes récurrents de qualité de fabrication (finitions, alignement des panneaux de carrosserie), un service après-vente encore insuffisamment dense pour absorber la croissance des volumes, et une dépendance excessive à la personnalité de son fondateur qui génère une volatilité de l'image de marque. Son positionnement exclusivement sur le haut de gamme (Model 3, Model Y, Model S, Model X) limite sa capacité à conquérir les segments de masse, segment sur lequel Renault avec la R5 E-Tech Electric et Dacia avec la Spring disposent d'un avantage concurrentiel certain.

En matière d'analyse des sentiments clients, Tesla bénéficie d'une communauté en ligne particulièrement active et d'un capital sympathie fort sur les réseaux sociaux, mais souffre d'une polarisation croissante des opinions liée aux controverses entourant son dirigeant. Comparativement, Renault dispose d'une base client plus large et plus diversifiée, mais doit déployer davantage d'efforts pour capturer et analyser systématiquement la voix de ses clients.

3.3 Analyse concurrentielle — Volkswagen Group

Le Groupe Volkswagen (VW Group), dont le siège est établi à Wolfsburg en Allemagne, constitue l'acteur automobile le plus puissant en Europe et le deuxième mondial en termes de volumes. En 2023, le groupe a vendu 9,24 millions de véhicules et réalisé un chiffre d'affaires de 322,3 milliards d'euros, avec une marge opérationnelle de 6,5 %. Son portefeuille de marques est exceptionnel : Volkswagen, Audi, Porsche, Skoda, Seat/Cupra, Lamborghini, Bentley et Ducati lui permettent de couvrir l'intégralité du spectre tarifaire du marché automobile mondial.

La stratégie électrique du groupe repose sur la plateforme MEB (Modularer E-Antriebs-Baukasten), mutualisée entre plusieurs marques et modèles (ID.3, ID.4, Skoda Enyaq, Audi Q4 e-tron). Cette approche plateforme permet une réduction significative des coûts de développement et de production. Le groupe a investi 180 milliards d'euros sur la période 2023-2027 dans l'électrification et la numérisation, dont une part substantielle est consacrée au développement de logiciels via sa filiale CARIAD.

Toutefois, le VW Group traverse une période de turbulences opérationnelles : la filiale logicielle CARIAD a connu des retards et dépassements de coûts significatifs, retardant le lancement de plusieurs modèles clés. Le groupe a également été confronté en 2023-2024 à une dégradation de sa rentabilité liée à la montée en puissance des constructeurs chinois sur son marché domestique et à la baisse des volumes en Chine, marché historiquement crucial. Des plans de réduction des coûts drastiques, incluant des fermetures d'usines en Allemagne, ont été annoncés fin 2024, suscitant une vive controverse sociale.

En matière de gestion de la réputation et d'analyse client, le VW Group souffre encore du traumatisme du Dieselgate (2015), qui a profondément entaché la confiance des

consommateurs et continue d'alimenter des analyses de sentiment négatives dans les recherches académiques et sectorielles. Ce contexte illustre parfaitement l'importance stratégique d'un système robuste de monitoring du sentiment client, capable de détecter précocement les signaux faibles de crise de réputation.

Synthèse comparative : Face à Tesla et au VW Group, Renault dispose d'atouts distincts : une gamme électrique accessible (R5 E-Tech, Mégane E-Tech, Dacia Spring), une ancrage territorial fort en Europe, et une agilité stratégique retrouvée sous l'impulsion du plan futuREady. Sa principale faiblesse résidé dans la moindre maturité de ses outils d'exploitation de la donnée client, ce que le présent projet ambitionne précisément de corriger.

4. PROBLÉMATIQUE ET DÉFINITION DU BESOIN

4.1 Identification du problème métier

Chaque année, des dizaines de milliers d'avis consommateurs portant sur les véhicules et services Renault sont publiés sur des plateformes telles que Trustpilot, Google Reviews, les forums spécialisés (Caradisiac, Auto Plus, Automobile Magazine), les réseaux sociaux (Twitter/X, Facebook, Reddit) et les comparateurs automobiles. Cette masse d'informations constitue une source de valeur considérable pour comprendre les forces et faiblesses perçues de la marque, identifier les problèmes récurrents signalés par les clients et anticiper les risques réputationnels.

Or, dans la pratique, ces données ne sont que partiellement exploitées. Les équipes chargées de la satisfaction client disposent de capacités humaines limitées pour traiter manuellement des milliers de verbatims quotidiens, ce qui conduit inévitablement à des délais de réaction prolongés, à des biais de sélection dans l'analyse et à une incapacité à détecter des tendances émergentes avant qu'elles ne se transforment en crises réputationnelles. La problématique centrale de ce projet peut donc être formulée de la manière suivante :

> *« Comment automatiser l'analyse des avis clients portant sur Renault Group afin d'identifier en temps quasi réel les sentiments dominants, les thématiques saillantes et les signaux d'alerte, permettant ainsi aux équipes marketing, qualité et direction de prendre des décisions plus rapides et mieux informées ? »*

Cette problématique couvre plusieurs dimensions interdépendantes. D'abord, une dimension technologique : il s'agit de construire un pipeline de traitement du langage naturel (NLP) robuste, capable d'ingérer des textes hétérogènes (langues, formats, longueurs variables), de les prétraiter et de les classifier automatiquement. Ensuite, une dimension analytique : les résultats doivent être interprétables par des non-spécialistes de l'IA et restitués sous forme de visualisations claires et actionnables. Enfin, une dimension organisationnelle : les insights produits doivent s'intégrer dans les processus décisionnels existants des équipes marketing, qualité et direction de Renault.

4.2 Solution proposée et bénéfices attendus

La solution proposée consiste en le développement d'un système d'analyse de sentiment automatisé reposant sur des algorithmes de Machine Learning (régression logistique, SVM) et de Deep Learning (LSTM, BERT fine-tuné en français/anglais). Ce système traitera les avis consommateurs issus de jeux de données publics (Kaggle, data.gouv.fr) et produira une classification tridimensionnelle (positif / neutre / négatif) enrichie d'une extraction thématique par LDA (Latent Dirichlet Allocation) permettant d'identifier les sujets les plus fréquemment évoqués dans les commentaires.

Les bénéfices attendus pour Renault Group sont multiples et quantifiables. En termes d'efficacité opérationnelle, l'automatisation de l'analyse des verbatims permettrait de réduire de 70 à 80 % le temps consacré par les équipes à la lecture manuelle des avis, libérant ainsi des capacités analytiques pour des tâches à plus forte valeur ajoutée. En termes de réactivité, la détection automatique des signaux négatifs permettrait de déclencher des alertes en temps réel, réduisant significativement le délai de réaction face aux problèmes émergents. En termes d'intelligence marché, les cartographies thématiques produites constitueront un input précieux pour les équipes produit et R&D; dans la définition des feuilles de route des futurs modèles.

5. PILOTAGE DU PROJET ET PLANIFICATION

5.1 Méthode de gestion retenue : Scrum adapté

Le pilotage de ce projet s'appuie sur une adaptation de la méthodologie Scrum, qui constitue le cadre agile de référence pour les projets de Data Science de complexité intermédiaire. Le choix de Scrum se justifie par la nature itérative du travail de modélisation — chaque sprint permettant d'affiner les algorithmes en fonction des résultats obtenus — et par la nécessité de maintenir un dialogue régulier avec les parties prenantes métier pour valider la pertinence opérationnelle des livrables. Des sprints bimensuels de deux semaines structurent le calendrier, avec des cérémonies adaptées au contexte solo (daily asynchrone, sprint review, rétrospective hebdomadaire).

5.2 Retroplanning et jalons du projet

Phase	Tâches principales	Durée	Livrable
Sprint 0 Sep. 2025	Cadrage, recherche documentaire, choix des sources de données	2 sem.	Note de cadrage
Sprint 1 Oct. 2025	Collecte et consolidation des données, analyse exploratoire (EDA)	2 sem.	Dataset nettoyé
Sprint 2 Nov. 2025	Prétraitement NLP, feature engineering, modèles baseline (LR, SVM)	2 sem.	Modèles baseline
Sprint 3 Déc. 2025	Deep Learning (LSTM, BERT), comparaison des modèles	2 sem.	Modèle final
Sprint 4 Jan. 2026	Visualisation, dashboard Power BI, documentation technique	2 sem.	Dashboard
Sprint 5 Fév-Mar 2026	Rédaction mémoire, révisions, préparation soutenance	4 sem.	Mémoire PDF
Rendu final Août 2026	Dépôt officiel et soutenance orale	—	NOM_PRENOM_THESE.pdf

** Retroplanning prévisionnel — adapté selon les contraintes rencontrées en cours de projet.*

5.3 KPI et tableau de bord de suivi du projet

Le suivi de l'avancement et de la qualité du projet s'appuie sur plusieurs indicateurs clés de performance (KPI), distinguant les indicateurs de pilotage projet des indicateurs de performance technique des modèles :

Dimension	KPI	Cible
Pilotage	Taux de complétion des sprints	> 85 %
Pilotage	Respect des délais de livraison	100 %

Données	Taux de complétion du dataset	> 95 %
Données	Taux d'incohérences identifiées et corrigées	> 90 %
Modèle ML	Accuracy sur jeu de test	> 85 %
Modèle ML	F1-Score macro (classes déséquilibrées)	> 0,82
Modèle DL	Amélioration vs baseline	> +5 pts accuracy
Dashboard	Temps de chargement du rapport Power BI	< 5 secondes

5.4 Estimation budgétaire prévisionnelle

Poste de dépense	Coût estimé (€)	Observations
Ressources humaines (étudiant alternant)	0 €	Projet académique
Infrastructure cloud (Google Colab Pro / AWS SageMaker)	150 – 300 €	GPU pour entraînement BERT
Licences logicielles (Power BI Pro)	120 €/an	Version Pro nécessaire
Sources de données (open data Kaggle)	0 €	Données publiques gratuites
Documentation et outils de gestion	0 – 50 €	Notion, Trello gratuits
TOTAL ESTIMÉ	**270 – 470 €**	**Budget maîtrisé**

6. EXPLOITATION DES DONNÉES

6.1 Identification des sources et volumétrie

Le projet s'appuie sur des jeux de données publics accessibles sur la plateforme Kaggle, complétés par des données extraites via des API publiques ou scraping légal de sites d'avis automobiles. Les sources principales retenues sont les suivantes :

Source	Format	Volume estimé	Contenu
Kaggle — Car Reviews Dataset	CSV	~50 000 lignes	Avis automobiles anglais, note 1-5, marque, modèle
Kaggle — French Sentiment Dataset	CSV/JSON	~30 000 lignes	Avis en français, polarité annotée
Trustpilot (API publique)	JSON	~10 000 lignes	Avis Renault France, étoiles, date, verbatim
data.gouv.fr — Véhicules électriques	CSV	~200 000 lignes	Données immatriculations, communes, modèles

6.2 Dictionnaire de données et typographie

Le dictionnaire de données ci-dessous décrit les variables principales du dataset consolidé utilisé pour l'entraînement des modèles :

Variable	Type	Format	Description	Valeurs possibles
review_id	Identifiant	String	Identifiant unique de l'avis	UUID ou entier
review_text	Texte	String	Verbatim complet de l'avis	Texte libre
rating	Numérique	Integer	Note attribuée par le client	1 à 5
sentiment_label	Catégorielle	String	Label de polarité annoté	positif / neutre / négatif
brand	Catégorielle	String	Marque du véhicule concerné	Renault, Dacia, Alpine...
model	Catégorielle	String	Modèle du véhicule	Mégane, Clio, R5...
review_date	Date	YYYY-MM-DD	Date de publication de l'avis	2018-2024
language	Catégorielle	String	Langue de l'avis	fr, en
source	Catégorielle	String	Plateforme d'origine	Trustpilot, Kaggle...
word_count	Numérique	Integer	Nombre de mots du verbatim	> 0

6.3 Qualité des données, sécurité et conformité RGPD

L'exploitation de données textuelles issues d'avis en ligne soulève des enjeux importants en matière de qualité et de conformité réglementaire. Sur le plan de la qualité, les problématiques suivantes ont été identifiées et feront l'objet d'un traitement systématique :

- **Valeurs manquantes :** les champs review_text et rating sont les variables critiques. Tout avis présentant un texte vide ou un rating absent sera exclu du dataset d'entraînement. Un compte-rendu précis du taux de complétude sera produit ;

- **Incohérences :** certains avis présentent une note élevée (4-5 étoiles) avec un texte négatif, ou inversement. Ces cas seront identifiés et traités comme des exemples bruités potentiellement exclus ou pondérés différemment lors de l'entraînement ;
- **Doublons :** une déduplication par hachage du texte (SHA-256) sera appliquée afin d'éviter le sur-apprentissage sur des avis identiques publiés sur plusieurs plateformes ;
- **Multilinguisme :** la détection automatique de la langue (via la bibliothèque langdetect) permettra de séparer les corpus français et anglais pour un traitement adapté.

Sur le plan de la conformité RGPD (Règlement Général sur la Protection des Données, règlement UE 2016/679), les mesures suivantes sont mises en œuvre. Les données utilisées proviennent exclusivement de sources publiques et anonymisées, conformément à l'article 89 du RGPD relatif au traitement à des fins de recherche. Aucune donnée permettant l'identification directe d'un individu (nom, adresse, email) n'est conservée dans le dataset de travail. Un pseudonymisat supplémentaire est appliqué via le remplacement des review_id par des identifiants internes générés aléatoirement. Le stockage des données s'effectue sur des environnements sécurisés (cloud chiffré, accès restreint par authentification). Un registre de traitement simplifié est tenu à jour conformément aux recommandations de la CNIL.

7. MACHINE LEARNING ET DEEP LEARNING — NLP

7.1 Introduction théorique au NLP et à l'analyse de sentiment

Le Traitement Automatique du Langage Naturel (TALN ou NLP — Natural Language Processing) est une branche de l'intelligence artificielle qui vise à permettre aux machines de comprendre, interpréter et générer du langage humain. Depuis les travaux fondateurs de Noam Chomsky sur la grammaire formelle dans les années 1950 jusqu'aux architectures Transformer contemporaines, le NLP a connu une évolution considérable, passant de systèmes basés sur des règles expertes à des approches statistiques puis neuronales.

L'analyse de sentiment (ou opinion mining) est une sous-tâche du NLP qui consiste à déterminer automatiquement la polarité affective d'un texte : positive, négative ou neutre. Dans sa forme la plus avancée, elle cherche également à identifier des émotions spécifiques (joie, colère, déception, surprise), à extraire les entités cibles des opinions (un modèle de véhicule particulier, une fonctionnalité, le service après-vente) et à mesurer l'intensité des sentiments exprimés. Cette granularité est particulièrement précieuse dans un contexte industriel comme celui de Renault, où l'identification des points de friction précis (batterie, interface numérique, réseau de charge) est plus utile qu'une mesure globale de satisfaction.

Le pipeline NLP classique comprend plusieurs étapes de prétraitement indispensables : la tokenisation (découpage du texte en unités lexicales), la normalisation (mise en minuscules, suppression de la ponctuation et des caractères spéciaux), l'élimination des mots vides (stopwords), la lemmatisation (réduction des mots à leur forme canonique) et la vectorisation (transformation des tokens en représentations numériques exploitables par les algorithmes). La qualité de ce prétraitement conditionne directement les performances des modèles en aval.

7.2 Algorithmes retenus et justification des choix techniques

Approche 1 — Modèles classiques de Machine Learning

En première approche, deux algorithmes de classification supervisée issus du Machine Learning classique sont entraînés afin d'établir des performances de référence (baseline). La **régression logistique** est choisie pour sa simplicité, son interprétabilité et ses bonnes performances empiriques sur les tâches de classification de texte courtes. Elle s'appuie sur une représentation TF-IDF (Term Frequency — Inverse Document Frequency) des textes, qui pondère chaque terme par sa fréquence relative dans le corpus et dans le document, capturant ainsi l'importance relative des mots. La **machine à vecteurs de support (SVM)** est également retenue pour sa robustesse sur les espaces de grande dimension caractéristiques des représentations bag-of-words et TF-IDF. Ces deux approches serviront de référence pour évaluer le gain apporté par les architectures plus complexes.

Approche 2 — Réseaux de neurones récurrents (LSTM)

Les réseaux de neurones à mémoire longue et à court terme (LSTM — Long Short-Term Memory), introduits par Hochreiter et Schmidhuber en 1997, constituent une avancée majeure des réseaux récurrents pour le traitement des séquences. Contrairement aux réseaux

récurrents simples, les LSTM intègrent un mécanisme de portes (gate mechanism) permettant de conserver sélectivement l'information pertinente sur des séquences longues, palliant ainsi le problème du gradient qui s'évanouit. Dans le contexte de l'analyse de sentiment, cette capacité à modéliser les dépendances à longue portée est particulièrement utile pour interpréter correctement des formulations complexes (négations, nuances, humour). Le modèle LSTM sera entraîné avec des embeddings pré-entraînés de type Word2Vec ou GloVe, fournissant une représentation sémantique dense des mots du corpus.

Approche 3 — Modèle BERT fine-tuné (CamemBERT / mBERT)

L'architecture Transformer, introduite par Vaswani et al. en 2017 dans l'article séminal « Attention is All You Need », a profondément révolutionné le domaine du NLP. Le modèle BERT (Bidirectional Encoder Representations from Transformers), développé par Google en 2018, en est l'une des applications les plus influentes. BERT se distingue par son mécanisme d'attention multi-tête qui lui permet de capturer les relations contextuelles bidirectionnelles entre les tokens d'une séquence, lui conférant une compréhension sémantique et syntaxique nettement supérieure aux architectures précédentes.

Pour les avis en français, le modèle CamemBERT (version BERT entraînée sur le corpus OSCAR en français, développée par l'Inria en 2020) sera utilisé et fine-tuné sur le dataset d'avis annotés. Pour les avis en anglais, le modèle multilingual BERT (mBERT) ou une version distillée (DistilBERT) sera privilégiée pour réduire les coûts de calcul tout en maintenant des performances élevées. Le fine-tuning consistera à ajouter une couche de classification à la représentation [CLS] du modèle pré-entraîné et à ajuster l'ensemble des poids sur le dataset spécifique au domaine automobile, avec un taux d'apprentissage faible (de l'ordre de 2×10^{-5}) pour préserver les représentations générales acquises lors du pré-entraînement.

7.3 Évaluation des performances du modèle

La division du dataset suit la règle des 70/15/15 : 70 % des données constituent le jeu d'entraînement, 15 % le jeu de validation (pour le réglage des hyperparamètres) et 15 % le jeu de test final (pour l'évaluation impartiale des performances). La stratification par classe de sentiment est appliquée pour garantir une distribution équilibrée dans chaque sous-ensemble.

Les métriques d'évaluation retenues sont les suivantes, leur choix étant justifié par la nature multi-classe potentiellement déséquilibrée du problème :

- **Accuracy (précision globale) :** proportion de prédictions correctes sur l'ensemble du jeu de test. Metrique intuitive mais insuffisante en cas de déséquilibre de classes ;
- **Precision, Recall et F1-Score par classe :** permettent d'évaluer finement les performances sur chaque catégorie (positif, neutre, négatif). Le F1-Score macro, qui fait la moyenne non pondérée des F1 par classe, est particulièrement adapté aux jeux déséquilibrés ;
- **Matrice de confusion :** visualisation des erreurs de classification croisée, permettant d'identifier les classes les plus souvent confondues et de cibler les axes d'amélioration ;
- **Courbe ROC et AUC (Area Under Curve) :** pour une évaluation en mode binaire (positif vs non-positif), permettant de mesurer la capacité discriminante du modèle indépendamment du seuil de décision.

Note : Les résultats numériques précis (accuracy, F1-Score, courbes d'apprentissage, matrices de confusion) seront produits par les scripts Python développés dans le cadre du projet et intégrés en annexe du présent mémoire, accompagnés des captures d'écran des sorties de modèles. Ces résultats ne peuvent être anticipés ici sans risquer d'introduire des données fictives.

7.4 Visualisation des données et tableau de bord Power BI

La restitution des analyses constitue une composante essentielle du projet. Un tableau de bord Power BI multi-pages sera développé pour permettre aux équipes Renault de naviguer intuitivement dans les résultats de l'analyse de sentiment. Les visualisations prévues comprennent :

- **Distribution des sentiments :** graphique en anneau (donut chart) présentant la répartition globale positif / neutre / négatif sur l'ensemble du corpus ;
- **Évolution temporelle des sentiments :** courbes d'évolution mensuelle de la proportion de chaque polarité, permettant de détecter les pics d'insatisfaction corrélés à des événements (lancement de modèle, campagne publicitaire, rappel) ;
- **Nuage de mots thématiques :** word clouds différenciés par polarité, faisant ressortir les termes les plus caractéristiques des avis positifs et négatifs ;
- **Heatmap modèle × sentiment :** matrice de chaleur croisant les modèles de véhicules mentionnés et les polarités associées, permettant d'identifier les modèles les plus et les moins bien perçus ;
- **Extraction des thèmes LDA :** visualisation des thèmes latents extraits par l'algorithme LDA (Latent Dirichlet Allocation), avec les mots-clés associés à chaque thème ;
- **Top avis positifs et négatifs :** tableau des verbatims les plus représentatifs de chaque polarité, facilitant la compréhension qualitative des résultats quantitatifs.

8. CONCLUSION

Ce mémoire professionnel a exposé la conception et le développement d'un système d'analyse automatique des sentiments clients appliqué à Renault Group, en mobilisant les techniques les plus avancées du Traitement Automatique du Langage Naturel. Inscrit dans un contexte de transformation numérique profonde de l'industrie automobile et de montée en puissance des véhicules électriques, ce projet répond à un besoin métier concret : permettre à une entreprise de la taille et de la complexité de Renault d'exploiter systématiquement et en temps quasi réel la richesse informationelle que constituent les avis de ses millions de clients à travers le monde.

Sur le plan technique, le projet illustre la complémentarité des approches de Machine Learning classique et de Deep Learning dans le traitement de données textuelles. Les modèles de référence basés sur TF-IDF (régression logistique, SVM) offrent une performance solide avec un coût computationnel faible et une grande interprétabilité. Les architectures LSTM et BERT permettent de capturer des nuances sémantiques plus fines au prix d'une complexité accrue, justifiant leur recours pour les cas d'usage à forte valeur ajoutée. La combinaison de ces approches dans un pipeline de traitement robuste, restitué via un tableau de bord Power BI, constitue une solution opérationnelle adaptée aux contraintes de l'entreprise.

Contraintes et risques identifiés

- **Qualité des données :** les avis publics présentent un bruit important (fautes d'orthographe, argot, mélange de langues) qui peut dégrader les performances des modèles malgré le prétraitement ;
- **Déséquilibre des classes :** dans la plupart des corpus d'avis, les opinions positives sont sur-représentées, ce qui peut biaiser les modèles en faveur de cette classe. Des techniques de rééquilibrage (oversampling SMOTE, class weighting) seront nécessaires ;
- **Ambiguïté sémantique :** certains avis présentent des sentiments mixtes ou ironiques difficiles à classifier automatiquement, constituant une limite intrinsèque des approches actuelles ;
- **Coûts computationnels :** le fine-tuning de BERT sur un GPU de classe grand public peut prendre plusieurs heures et nécessite une infrastructure cloud adaptée ;
- **Conformité RGPD :** bien que les données soient publiques, leur utilisation dans un contexte professionnel requiert une vigilance permanente sur les aspects légaux.

Perspectives d'évolution

Plusieurs axes d'évolution peuvent être envisagés pour enrichir et étendre le système développé dans le cadre de ce projet. À court terme, l'extension du corpus à d'autres langues (espagnol, allemand, portugais) permettrait d'élargir la couverture géographique de l'analyse aux marchés clés de Renault en Europe et en Amérique Latine. À moyen terme, l'intégration d'une fonctionnalité d'analyse des sentiments au niveau des aspects (ABSA — Aspect-Based Sentiment Analysis) permettrait d'identifier avec précision quels attributs spécifiques des véhicules (autonomie, recharge, design, habitacle, prix) génèrent les opinions les plus positives

ou négatives.

À long terme, le couplage de ce système avec les données CRM de Renault (avec les adaptations RGPD nécessaires) ouvrirait des perspectives d'analyse encore plus puissantes : corrélation entre sentiments exprimés en ligne et comportements d'achat réels, personnalisation des communications marketing en fonction du profil émotionnel du client, détection précoce des risques de désabonnement ou de résiliation. Ces évolutions s'inscrivent parfaitement dans la vision stratégique futuREady de Renault Group, qui fait de la maîtrise de la donnée client un pilier fondamental de sa compétitivité à horizon 2030.

En définitive, ce projet témoigne de la capacité de la Data Science et de l'Intelligence Artificielle à transformer une ressource largement sous-exploitée — les avis en ligne des consommateurs — en un véritable avantage concurrentiel, à condition d'en maîtriser les techniques, les enjeux et les responsabilités éthiques. C'est précisément la vocation du Mastère Data & Intelligence Artificielle que de former des professionnels capables de relever ce défi avec rigueur, créativité et sens des responsabilités.

BIBLIOGRAPHIE

[1] Agence Internationale de l'Énergie (AIE). (2024). *Global EV Outlook 2024*. Paris : IEA. Disponible sur : https://www.iea.org/reports/global-ev-outlook-2024

[2] ACEA — Association des Constructeurs Européens d'Automobiles. (2024). *New Car Registrations Full-Year 2023*. Bruxelles : ACEA.

[3] AVERE France. (2024). *Tableau de bord du marché du véhicule électrique en France — 2023*. Paris : AVERE.

[4] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT 2019*, 4171-4186.

[5] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780.

[6] Martin, L., Muller, B., Suárez, P. J. O., et al. (2020). CamemBERT: a Tasty French Language Model. *Proceedings of ACL 2020*.

[7] McKinsey & Company. (2023). *Capturing the automotive industry's digital opportunity*. McKinsey Center for Future Mobility.

[8] MarketsandMarkets. (2024). *Natural Language Processing Market — Global Forecast to 2028*.

[9] OICA — Organisation Internationale des Constructeurs d'Automobiles. (2024). *World Motor Vehicle Production Statistics 2023*. Paris : OICA.

[10] Pang, B., & Lee, L. (2008). Opinion Mining and Sentiment Analysis. *Foundations and Trends in Information Retrieval*, 2(1-2), 1-135.

[11] Renault Group. (2024). *Rapport Annuel et Document d'Enregistrement Universel 2023*. Boulogne-Billancourt : Renault Group.

[12] Renault Group. (2023). *Stratégie futuREady — Présentation aux investisseurs*. Boulogne-Billancourt : Renault Group.

[13] Union Européenne. (2023). *Règlement (UE) 2023/851 du Parlement européen et du Conseil relatif aux normes d'émissions de CO2 des voitures particulières et des véhicules utilitaires légers*. Journal officiel de l'Union européenne.

[14] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention is All You Need. *Advances in Neural Information Processing Systems*, 30.

[15] Volkswagen Group. (2024). *Annual Report 2023*. Wolfsburg : Volkswagen AG.

[16] JD Power. (2023). *U.S. Initial Quality Study (IQS) 2023*. Troy, MI : JD Power.

[17] CNIL — Commission Nationale de l'Informatique et des Libertés. (2023). *Guide pratique RGPD pour les développeurs*. Paris : CNIL.

ANNEXES

Annexe A — Architecture du pipeline NLP

Le schéma ci-dessous présente l'architecture globale du pipeline de traitement développé dans le cadre du projet. Il sera complété par les captures d'écran des notebooks Python lors de la soutenance.

Étape	Composant	Outil / Bibliothèque
1	Collecte des données	Kaggle API, Requests, BeautifulSoup
2	Stockage brut	MongoDB (NoSQL) / CSV
3	Prétraitement NLP	NLTK, spaCy, regex
4	Vectorisation	TF-IDF (Scikit-learn), Word2Vec, BERT Tokenizer
5	Entraînement Modèles ML	Scikit-learn (LR, SVM)
6	Entraînement Modèles DL	TensorFlow/Keras (LSTM), HuggingFace Transformers (BERT)
7	Évaluation	Scikit-learn metrics, Matplotlib, Seaborn
8	Stockage résultats	SQL / PostgreSQL
9	Visualisation	Power BI, Plotly

Annexe B — Environnement technique

Catégorie	Outil / Technologie	Usage dans le projet
Langage	Python 3.11	Développement principal
Notebooks	Jupyter Notebook / Google Colab	Exploration et modélisation
ML	Scikit-learn 1.4	Modèles classiques, métriques
DL	TensorFlow 2.15 / Keras	LSTM
NLP	HuggingFace Transformers 4.x	BERT / CamemBERT
NLP	NLTK, spaCy, langdetect	Prétraitement textuel
BDD NoSQL	MongoDB 7.x	Stockage des avis bruts
BDD SQL	PostgreSQL 16	Stockage des résultats
Viz	Power BI Desktop	Dashboard final
Viz	Matplotlib, Seaborn, Plotly	Graphiques exploratoires

Gestion de projet	Notion / Trello	Suivi Scrum
Versioning	Git / GitHub	Contrôle de version du code